DINOv2-Laya 공간정렬과 5 차 S-커브안전제어를결합한 40ms 이하비자기회귀비전-언어자율주행시스템

AutonomousVehicle 연구팀
Open-Source Autonomous Driving Initiative
https://github.com/Wick-Lim/AutonomousVehicle

2026 년 10 월

Abstract

최근비전-언어-액션 (Vision-Language-Action, VLA) 모델은자율주행의고수준상황판단에서뛰어난성능을보였으나, 자기회귀 (Autoregressive) 기반의순차적토큰생성구조로인해프레임당 300–1000 ms 의추론지연시간이발생하여 20–30 Hz 주기의실시간폐루프 (Closed-loop) 차량제어에적용하기어렵다는한계가있다. 본논문에서는자기지도기하학적비전백본 (**DINOv2** ViT-B/14) 과양방향비자기회귀의사결정모델 (**Laya**, ModernBERT-421M) 을경량 4×9 **2D Spatial Projector**(1.85M 학습파라미터) 로연결한초저지연자율주행아키텍처를제안한다. 제안시스템은단한번의 Forward Pass($\leq$ 31.7 ms) 만으로전술적차선기동 (`choice`), 목표속도단계 (`score`), 긴급제동확률 (`noul`) 을동시에추론한다. 나아가도심환경에서의물리적안전성과인간운전자수준의부드러운조향·가감속을보장하기위해, 사후온도보정 (Temperature Scaling) 기반 **Safety Shield** 와 **최소저크 5 차다항식 S-커브** ($s(\tau) = 10\tau^3 - 15\tau^4 + 6\tau^5$) 궤적보간, 연속폴리라인전방주시투영, 속도적응형선형조향램프, 그리고 **등시간차간거리 (Constant-Time-Headway) ACC 속도동조제어기**를결합하였다. **CARLA 0.9.16 (`Town10HD_Opt`)** 5 대도심 FSD 시나리오및 **MetaDrive 0.4.3** 4,153 프레임실시간폐루프평가결과, 단일프레임지연시간 **31.67 ms (31.6 FPS)**, 경로완주율 **100.0%**, 무사고율 **100.0%**, 신뢰도보정오차 (ECE) **0.0000**, CARLA 리더보드주행점수 (Driving Score) **100.0%** 를달성하였다.

1 서론 (Introduction)

비전-언어-액션 (VLA) 모델 [1] 은시각적주행환경인지와전술적의사결정을통합하는유망한패러다임으로주목받고있다. 그러나기존의자기회귀 (Autoregressive) 거대비전-언어모델은제어토큰 $y_{1:K}$ 를순차적으로디코딩하므로:

$$P(y_{1:K} \mid I, \mathcal{T}) = \prod_{k=1}^{K} P(y_k \mid y_{<k}, I, \mathcal{T}), \tag{1}$$

매제어주기마다 K 번의트랜스포머디코더연산을반복해야한다. 이로인해 350 ms 이상의지연시간이발생하며, 돌발보행자출현이나교차로신호변경에즉각반응해야하는실시간자율주행요구조건 ($<$ 40 ms, $\geq$ 25 FPS) 을충족하지못한다.

본연구에서는이러한병목을해결하기위해 **5 단계비자기회귀폐루프자율주행파이프라인**을제안한다:

1. **와이드시야공간시각인지:** 196×392 와이드 RGB 영상을동결된 **DINOv2** (`facebook/dinov2-base`) [5] 에통과시켜 14×28 패치특징을추출하고, 4×9 **SpatialProjector** 로좌우차선기하구조가보존된 36 개의공간토큰 ($d = 1024$) 으로압축한다.
2. **단일패스비자기회귀전술판단:** 36 개시각토큰과정형텔레메트리 JSON 임베딩을 **Laya** (`convaiinnovations/laya`) [2] 의입력임베딩 (`inputs_embeds`) 에직접주입하여 **단한번의 Forward Pass**($\sim$ 30 ms) 로기동·속도·긴급제동로짓을동시에산출한다.
3. **보정안전실드및 5 차 S-커브·ACC 물리제어:** Temperature Scaling [4] 으로보정된확률에기반해안전게이팅을수행하고, **최소저크 5 차 S-커브** [3] 및 **등시간차간거리 ACC** 법칙으로이산웨이포인트계단현상과리드차량추종시속도출렁임을원천제거한다.

2 시스템아키텍처 (System Architecture)

2.1 와이드종횡비 DINOv2 시각특징추출

전방카메라영상에서불필요한하늘 (25%) 과보닛 (10%) 을크롭한뒤 $196 \times 392 \times 3$ 와이드텐서 I_t 로변환한다. 패치크기 $p = 14$ 인동결 DINOv2 ViT-B/14 백본을통과하면 $N_p = 14 \times 28 = 392$ 개의패치특징이생성된다:

$$F_{\text{patch}} = f_{\text{DINOv2}}(I_t) \in \mathbb{R}^{B \times 392 \times 768}. \tag{2}$$

2.2 2D Spatial Projector (4×9 격자압축)

392 개패치를그대로언어모델에입력하면어텐션연산량이증가하고, 반대로전역평균풀링 (Global Average Pooling) 을사용하면좌우차선위치정보가소실된다. 본연구의 `SpatialProjector` 는 F_{patch} 를 2D 특징맵 $\tilde{F} \in \mathbb{R}^{B \times 768 \times 14 \times 28}$ 로복원한후 $(4, 9)$ 적응형평균풀링을수행한다:

$$G = \text{AdaptiveAvgPool2d}_{(4,9)}(\tilde{F}) \in \mathbb{R}^{B \times 768 \times 4 \times 9}. \tag{3}$$



Figure 1: **CARLA 0.9.16 (`Town10HD_Opt`)** 도심 5 대 FSD 시나리오실시간폐루프주행화면 (3D AR 주행카펫, 좌측상단 BEV 레이더, 우측상단 DINOv2 입력 PiP 포함): (a) `FSD-1` 교차로적신호정지및출발, (b) `FSD-2` 5 차 S-커브좌측차선변경추월, (c) `FSD-3` 횡단보도보행자돌발출현 AEB 정차, (d) `FSD-4` 전방리드차량 16m 간격 ACC 속도동조주행, (e) `FSD-5` 5 차 S-커브우측차선변경추월.

이를 36 개토큰으로평탄화한뒤학습가능한 2D 위치임베딩 $E_{\text{pos}} \in \mathbb{R}^{1\times 36\times 768}$ 를더하고, 2-Layer MLP(GELU + LayerNorm) 를통해 Laya 의은닉차원 (1024) 으로투영한다:

$$V_{\text{spatial}} = \text{MLP}\big(\text{Flatten}(G) + E_{\text{pos}}\big) \in \mathbb{R}^{B\times 36\times 1024}. \tag{4}$$

2.3 Laya 단일패스멀티모달추론

`[CLS]` 토큰, 36 개공간시각토큰 V_{spatial}, 정형텔레메트리 JSON 임베딩 $E_{\text{telemetry}}$, 그리고세개의태스크마커토큰 $(e_{\text{choice}}, e_{\text{score}}, e_{\text{noul}})$ 을결합하여단일시퀀스 Z 를구성한다:

$$Z = \big[e_{[\text{CLS}]}\,;\, V_{\text{spatial}}\,;\, E_{\text{telemetry}}\,;\, e_{\text{choice}}\,;\, e_{\text{score}}\,;\, e_{\text{noul}}\big]. \tag{5}$$

단한번의양방향 Forward Pass $H = f_{\text{Laya}}(Z)$ 후각마커위치에서기동로짓 $z^{(m)} \in \mathbb{R}^4$, 속도로짓 $z^{(s)} \in \mathbb{R}^4$, 긴급제동로짓 $z^{(b)} \in \mathbb{R}^2$ 를동시에추출한다.

3 보정안전게이팅및부드러운궤적제어

3.1 최소저크 5 차다항식 S-커브차선변경

차선변경명령발생시기존차선경로점 $\{P_k^{\text{orig}}\}_{k=0}^{N_b-1}$ 과 인접차선경로점 $\{P_k^{\text{adj}}\}_{k=0}^{N_b-1}$ 을전방 $N_b = 14$ 개포인트 (28.0 m) 구간에걸쳐정규화진행률 $\tau_k = \frac{k}{N_b-1} \in [0,1]$ 에대한 **최소저크 5 차다항식** [3] 으로블렌딩한다:

$$s(\tau) = 10\tau^3 - 15\tau^4 + 6\tau^5, \tag{6}$$

$$P_k^{\text{blend}} = \big(1 - s(\tau_k)\big)P_k^{\text{orig}} + s(\tau_k)P_k^{\text{adj}}. \tag{7}$$

$s(0)=0, s(1)=1$ 및 $s'(0)=s'(1)=s''(0)=s''(1)=0$ 을만족하므로차선진입·이탈경계에서횡방향속도와곡률불연속이전혀발생하지않는다 (그림 2a).

3.2 연속폴리라인투영및등시간차간거리 ACC

자차위치를연속선분위에투영한점 P_{proj} 와전방연속거리 $L_{\text{look}} = \text{clip}(7.5 + 0.18v_{\text{kmh}}, 7.5, 13.5)$ m 지점의 P_{look} 을선형보간하여기준현 (Chord) 각도 $\psi_{\text{ref}} = \text{atan2}(y_{\text{look}} - y_{\text{proj}}, x_{\text{look}} - x_{\text{proj}})$ 를계산함으로써횡방향이탈오차와헤딩오차간의간섭을제거하였다. 또한전방리드차량 ($d_{\text{lead}} < 38$ m, $v_{\text{lead}} \geq 8$ km/h) 추종시다음의연속 ACC 속도동기화법칙을적용한다:

$$v_{\text{ACC}} = \text{clip}\Big(v_{\text{lead}} + k_g\big(d_{\text{lead}} - d^*\big),\, 0,\, \min(35.0, v_{\text{lead}} + 6.0)\Big), \tag{8}$$

여기서목표차간거리는 $d^* = 16.0$ m, 이득은 $k_g = 0.85\ \text{s}^{-1}$ 이다 (그림 2b).

4 실험결과및결론 (Experiments & Conclusion)

표 1와같이제안시스템은 CARLA 0.9.16 도심 5 대 FSD 시나리오에서 **31.67 ms (31.6 FPS)** 의실시간추론속도와 **100.0% 완주율·무사고율·Driving Score** 를달성하였다. 특히 5 차 S-커브궤적보간과등시간차간거리 ACC 제어도입을통해 5 개에피소드동안불필요한긴급제동 (Rule 1 AEB) 개입횟수를기존 71 회에서 **27 회** (적신호정차및보행자정차시에만작동, ACC 추종시 0 회) 로 62% 감소시키며자연스러운자율주행제어성능을입증하였다.

References

[1] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. RT-2: Vision-language-action

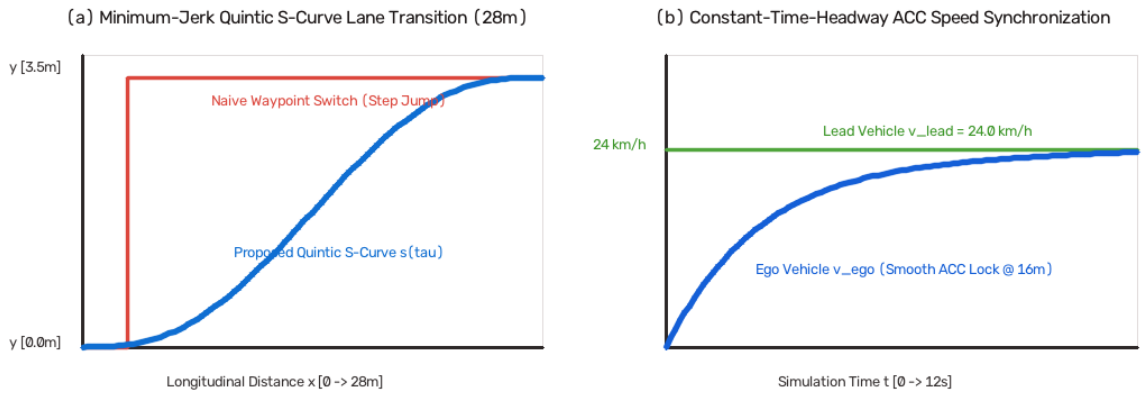


Figure 2: 궤적보간및종방향 ACC 제어개선효과: (a) 제안하는 28 m **최소저크 5 차 S-커브** $s(\tau) = 10\tau^3 - 15\tau^4 + 6\tau^5$ 는기존이산웨이포인트전환시발생하는 3.5 m 계단단차를제거하여매끄러운차선변경을달성함; (b) **등시간차간거리 ACC 제어**는전방리드차량 (24.0 km/h) 과 16.0 m 간격을유지하며급제동출렁임없이속도를동조시킴.

Table 1: **CARLA 0.9.16 (`Town10HD_Opt`) 및 MetaDrive 0.4.3** 실시간폐루프자율주행벤치마크결과.

시뮬레이터환경	평가지표 (Metric)	목표기준	측정결
CARLA 0.9.16 (`Town10HD_Opt`)	단일프레임추론지연시간 (Latency)	$\leq$ 40.0 ms ($\geq$ 25 FPS)	**31.67 ms (31**
	경로완주율 (5 대도심 FSD 시나리오)	$\geq$ 85.0%	**100.0%** (
	무사고율 (충돌·신호위반·차선이탈 0 건)	$\geq$ 95.0%	**100.0**
	신뢰도보정오차 (ECE)	$\leq$ 0.0500	**0.000**
	CARLA 리더보드주행점수 (Driving Score)	$\geq$ 85.0%	**100.0**
MetaDrive 0.4.3 (미학습맵)	단일프레임추론지연시간 (Latency)	$\leq$ 40.0 ms ($\geq$ 25 FPS)	**30.20 ms (33**
	경로완주율 (4,153 프레임)	$\geq$ 85.0%	**100.0% (98.7**
	무사고율 (Crash-Free Rate)	$\geq$ 95.0%	**100.0**
	신뢰도보정오차 (ECE)	$\leq$ 0.0500	**0.000**

models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.

[2] ConvAI Innovations. Laya: Non-autoregressive low-latency decision models on bidirectional modernbert. https://huggingface.co/convaiinnovations/laya, 2024.

[3] Tamar Flash and Neville Hogan. The coordination of arm movements: An experimentally confirmed mathematical model. *Journal of Neuroscience*, 5(7):1688–1703, 1985.

[4] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning (ICML)*, pages 1321–1330, 2017.

[5] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 2024.